

Progetto Data Warehouse

Brazilian E-Commerce

Francesco Tartaglia

Luglio 2026

Indice

1	Introduzione al Dominio e Obiettivi	2
1.1	Preliminary workload	2
1.2	Dominio del database sorgente	2
2	Architettura del progetto	3
2.1	Staging Area	3
2.2	Reconciled Layer (ODS)	4
3	Data Cleaning, Transformation e Data Quality Metrics	5
3.1	Data Quality Metrics	5
3.2	Data Cleaning and Transformation	5
4	Logical Schema	6
5	Attribute Tree	7
6	Fact Schema e Granularità	7
7	Glossario delle Misure	7
8	Star Schema	10

1 Introduzione al Dominio e Obiettivi

Contesto: "Il presente progetto si basa sul dataset Olist Brazilian E-commerce, utile per analisi di business e data Warehouse perché consente di studiare quelli che sono i comportamenti tipici di: vendite; clienti; trend di fatturato; ecc. La fonte è disponibile su Kaggle (<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>).

Il seguente dataset riguarda un campione di ordini venduti da diversi marketplace in Brasile, racconta la storia di come il mercato brasiliano sia cresciuto dal 2016 al 2018, fornendo dimensioni utili per poter analizzare il ciclo di vita di ogni ordine.

Obiettivo del Data Warehouse: "L'obiettivo strategico del sistema è fornire una vista centralizzata e multidimensionale degli eventi di vendita (**fact_sale_item**), permettendo analisi approfondite su tre macro-aree: Performance Finanziarie (ricavi e costi di spedizione), Efficienza Logistica (tempi di consegna) e Soddisfazione del Cliente (recensioni). L'infrastruttura sfrutta dimensioni a bassa granularità, come geografie complete (cliente e venditore) e attributi fisici dei prodotti, per individuare inefficienze e opportunità di mercato."

Il Data Warehouse finale contiene 112.650 record nella **fact_sale_item**, connessi a 96.096 clienti, 3.095 venditori, 32.951 prodotti e 28 combinazioni di pagamento.

Il progetto è reperibile al seguente link: <https://github.com/gitCiccio/Olist-Brazilian-E-commerce>.
git

1.1 Preliminary workload

Per soddisfare gli obiettivi strategici delineati, il design del Data Warehouse è stato guidato da uno specifico Preliminary Workload. Di seguito vengono formalizzate le principali interrogazioni multidimensionali (query OLAP) a cui il sistema, grazie alla sua struttura a stella e alla granularità del singolo **order_item**, è in grado di rispondere:

1. Qual è il punteggio medio delle recensioni (**review_score**) e la percentuale di ordini non recensiti, analizzati per categoria di prodotto e per stato di residenza del cliente?
2. Qual è l'andamento temporale (su base mensile e trimestrale) dei volumi di vendita (**item_count**) e dei ricavi totali (**price**) lungo l'intero biennio di osservazione?
3. Qual è il ritardo medio di consegna (calcolato confrontando le date di consegna effettiva e stimata in **dim_date**) ripartito per regione del cliente e mese di spedizione?
4. Quali sono le prime 5 categorie di prodotto più vendute (in termini di ricavi) in ciascuno stato brasiliano, e come incide il costo di spedizione (**freight_value**) sugli acquisti in tali aree?

1.2 Dominio del database sorgente

Olist collega diversi piccoli business in tutto il Brasile. Qui ogni commerciante ha la possibilità di vendere i propri prodotti attraverso Olist Store e spedirli direttamente ai propri acquirenti tramite i partner di Olist che si occupano delle spedizioni. Il dataset pubblicato da Olist non è altro che un insieme di diversi dataset collegati tra di loro, i dataset interessati sono:

- Olist order Reviews
- Olist orders
- Olist order customer
- Olist order payments

- Olist order items
- Olist products
- Olist sellers
- Olist geolocalization

2 Architettura del progetto

Per il mio progetto, per scopo totalmente didattico, ho realizzato un'architettura a tre livelli (Three-Tier Architecture), dove i livelli si dividono rispettivamente in:

- staging area;
- reconciled layer;
- data warehouse.

2.1 Staging Area

I dati sorgenti sono stati estratti e caricati nella Staging Area nel loro formato originale (raw), senza subire alcuna alterazione o operazione di trasformazione ETL, in modo da mantenere la massima fedeltà con le fonti.

In questa fase non è stato imposto alcun vincolo di integrità referenziale. Tuttavia, per prevenire errori in fase di caricamento massivo e rispecchiare la semantica dei campi sorgente, è stato effettuato fin dall'inizio un mapping rigoroso dei tipi di dato principali (es. INTEGER, TIMESTAMP, NUMERIC).




Figura 1: Architettura della Staging Area

2.2 Reconciled Layer (ODS)

I dati provenienti dalla Staging Area sono stati sottoposti a operazioni di pulizia, standardizzazione e integrazione. In questo livello le tabelle mantengono la struttura relazionale (3NF) e la granularità originale, fungendo da base solida per la successiva modellazione dimensionale.

Durante il popolamento del Reconciled Layer sono state applicate le seguenti trasformazioni e arricchimenti:

- **Arricchimento Geografico:** Aggiunta dell'attributo **region** alle tabelle **rcl_customers** e **rcl_sellers**. Questo passaggio espande la gerarchia spaziale nativa, facilitando le future aggregazioni territoriali nel Data Warehouse.
- **Flag di Data Quality e Cast:** Introduzione di campi booleani per isolare anomalie a valle della pulizia, tra cui **state_valid_flag** (per validare le sigle degli stati) e **review_score_valid_flag** (nella tabella **rcl_order_reviews**). Inoltre, le coordinate in **rcl_geolocation** sono state convertite in un più rigoroso **NUMERIC(12,8)**.
- **Enforcement dei Vincoli:** Imposizione del vincolo **NOT NULL** su tutte le chiavi di business (es. **order_id**, **product_id**) e sugli attributi analitici fondamentali, garantendo che nell'ODS convergano esclusivamente record completi e formalmente validi.
- **Predisposizione SCD Type 2:** Strutturazione delle entità cliente e venditore per supportare le Slowly Changing Dimension di Tipo 2. Sono stati implementati gli attributi di validità temporale (**valid_from**, **valid_to**) e il flag **is_current**, supportati da vincoli logici (**CHECK valid_to >= valid_from**) e indici parziali (**UNIQUE ON natural_key WHERE is_current = TRUE**). Questo rende il modello in grado di storicizzare eventuali variazioni geografiche o anagrafiche nel tempo.




Figura 2: Schema Riconciliato (ODS)

3 Data Cleaning, Transformation e Data Quality Metrics

I dati estratti sono stati sottoposti a processi di validazione, pulizia e trasformazione tramite script Python dedicati, generando un report JSON tracciabile, prima di essere consolidati nel Livello Riconciliato e nel Data Warehouse.

3.1 Data Quality Metrics

Le metriche di qualità dei dati sono state calcolate come segue:

- **Validity:** verifica che i valori rispettino i domini predefiniti (es. controllo tramite Regex per le sigle degli stati brasiliani; vincoli di dominio numerico per `price` e `freight_value`).
- **Completeness:** misura il rapporto percentuale tra celle valorizzate e celle totali, calcolato esclusivamente sulle colonne identificate come obbligatorie.
- **Consistency:** verifica l'integrità logica e referenziale confrontando i record trasformati con quelli effettivamente caricati nel sistema.
- **Uniqueness:** calcolata sulle Business Key principali (`customer_unique_id`, `order_id`) per quantificare ed eliminare i duplicati presenti nei dataset originali.

Metric	Value (%)
Validity	100.00 %
Completeness	100.00 %
Consistency	100.00 %
Uniqueness	100.00 %

Tabella 1: Metriche globali di Data Quality post-elaborazione.

3.2 Data Cleaning and Transformation

- **Customer & Seller:** I valori nulli nei campi città e stato sono stati sostituiti con default ('unknown', 'XX'). I testi sono stati uniformati in minuscolo e privati di accenti. È stata derivata la macro-regione tramite un dizionario statico ed è stata validata la correttezza formale della sigla dello stato tramite Regex, generando l'attributo `state_valid_flag`.
- **Orders:** I valori mancanti in `order_status` sono stati sostituiti con 'unknown'. Tutti gli attributi temporali sono stati forzati al formato standard datetime, convertendo le stringhe corrotte in valori nulli controllati (NaT) per preservare l'affidabilità delle JOIN.
- **Order Items:** I campi identificativi e quantitativi (`order_item_id`, `price`, `freight_value`) sono stati convertiti in formato numerico, mentre `shipping_limit_date` è stato tipizzato come datetime. Le stringhe anomale non convertibili sono state forzate a valore nullo.
- **Order Payment:** I metodi di pagamento grezzi sono stati standardizzati in quattro macro-categorie inglesi (`credit_card`, `debit_card`, `voucher`, `ticket`) tramite dizionario. I valori nulli o non validi sono stati mappati come 'not_defined'. Applicato il cast numerico alle colonne relative a rate e importi.

- **Order Review:** Validazione rigorosa del `review_score` per garantirne l'appartenenza al range [1, 5], con creazione del `review_score_valid_flag`. Le recensioni prive di testo sono state sostituite con stringhe vuote e le date standardizzate.
- **Products:** Le categorie merceologiche sono state tradotte dal portoghese all'inglese tramite tabella di lookup deduplicata. Le categorie mancanti sono state impostate su 'unknown' ed è stato eseguito il cast numerico per tutte le caratteristiche fisiche dei prodotti (dimensioni e peso).
- **Geolocation:** Pulizia testuale delle città, validazione Regex degli stati e conversione delle coordinate spaziali in formato numerico, con conseguente rimozione di circa 280.000 duplicati. Le coordinate puntuali hanno subito un processo di pruning, demandando la granularità geografica agli attributi consolidati `city`, `state` e `region`.
- **Date Standardization:** I timestamp estratti dagli ordini sono stati unificati nella dimensione temporale `dim_date`, strutturata come Role-Playing Dimension per rappresentare data di acquisto, limite di spedizione e consegna all'interno della medesima Fact Table.
- **Final Pruning & Consistency Checks:** Sulla tabella dei fatti (`fact_sale_item`) sono stati rimossi i record orfani o sprovvisti delle chiavi di business principali (`order_id`, `product_natural_key`, ecc.) e le transazioni prive di `order_item_id`. Per eliminare duplicati transazionali residui è stata generata una composite natural key (`order_id` + `order_item_id`). Infine, la dimensione di servizio `dim_payment` ha subito un pruning strutturale, collassando oltre 103.000 record operazionali in 28 combinazioni univoche.

4 Logical Schema

Il modello logico decompone il dataset e-commerce normalizzato in entità denormalizzate per supportare le query OLAP, producendo un'unica Fact Table centralizzata connessa a cinque dimensioni.

Measure Additivity: All'interno della tabella dei fatti (`fact_sale_item`), le misure `item_count`, `price` e `freight_value` sono additive e possono essere sommate (SUM) lungo qualsiasi combinazione dimensionale. La misura `review_score` è invece semi-additiva e richiede l'impiego dell'operatore media (AVG) per produrre risultati semanticamente validi.

Logical Schema: Le tabelle dimensionali utilizzano Surrogate Keys in formato UUID come Primary Keys (PK, in grassetto), slegate dalle chiavi dei sistemi operazionali. Le Foreign Keys sono contrassegnate con [FK].

- `dim_customer` (**surrogate_key**, `natural_key`, `customer_region`, `customer_city`, `customer_state`, `valid_from`, `valid_to`, `is_current`)
- `dim_seller` (**surrogate_key**, `natural_key`, `seller_region`, `seller_city`, `seller_state`, `valid_from`, `valid_to`, `is_current`)
- `dim_product` (**surrogate_key**, `natural_key`, `category_name_en`, `product_weight_g`, `product_length_cm`, `product_height_cm`, `product_width_cm`)
- `dim_payment` (**surrogate_key**, `payment_type`, `payment_installments`)
- `dim_date` (**surrogate_key**, `natural_key`, `full_date`, `day`, `month`, `quarter`, `year`, `day_of_week`, `week_of_year`, `is_weekend`)
- `fact_sale_item` (**surrogate_key**, `natural_key`, `order_id`, `order_item_id`, `order_status`, `item_count`, `price`, `freight_value`, `review_score`, `product_key` [FK], `customer_key` [FK], `seller_key` [FK], `payment_key` [FK], `purchase_date_key` [FK], `shipping_limit_date_key` [FK], `delivered_date_key` [FK], `estimated_delivery_date_key` [FK])

Relationships:

- Ogni record di `fact_sale_item` è identificato univocamente dalla composite key (`order_id`, `order_item_id`) e riferenzia esattamente un Customer, un Seller, un Product e un Payment.
- Un singolo ordine può contenere più item venduti da venditori differenti.
- In caso di duplicati sulle business key dimensionali è stata conservata esclusivamente la prima occorrenza logica.

5 Attribute Tree

Basandosi sullo schema relazionale intermedio, il design concettuale è stato sviluppato applicando i principi del Dimensional Fact Model (DFM). La performance di vendita del singolo articolo (Sale Item) è stata posta come Fatto centrale alla radice dell'albero.

L'Albero degli Attributi completo ha subito le seguenti operazioni di revisione:

- **Pruning (Potatura):** Rimozione dei livelli di dettaglio irrilevanti per l'analisi OLAP, inclusi i timestamp secondari (es. `order_approved_at`) e le coordinate puntuali spaziali della tabella geolocation.
- **Derivazione:** Inserimento di modifiche strutturali per formalizzare le gerarchie dimensionali, come la derivazione della macro-regione (`region`) dalla sigla dello stato.
- L'operazione di **Grafting (innesto)** non si è resa necessaria in quanto non sono stati rilevati nodi intermedi da bypassare.

6 Fact Schema e Granularità

Nel Fact Schema, gli attributi identificativi agiscono come dimensioni analitiche che connettono il Fatto alle rispettive gerarchie.

La granularità del Fatto è stata mantenuta al livello atomico originale della singola riga d'ordine (sale item) per garantire la tracciabilità delle dinamiche dei singoli prodotti e venditori, assicurando totale flessibilità per le successive aggregazioni di roll-up. All'interno del blocco centrale del diagramma sono state esplicitate le funzioni matematiche per definire l'additività delle misure: operatore SUM per le metriche additive (`price`, `freight_value`, `item_count`) e operatore AVG per la misura semi-additiva (`review_score`).

7 Glossario delle Misure

Il Data Warehouse espone le performance del business E-commerce attraverso quattro misure primarie contenute all'interno della Fact Table centralizzata (`fact_sale_item`). Al fine di garantire analisi coerenti e per abilitare le corrette operazioni OLAP (come Roll-up e Slice & Dice) all'interno delle dashboard, per ogni misura è stata definita formalmente la logica di aggregazione e il grado di additività:




Figura 3: Albero degli Attributi iniziale




Figura 4: Albero degli Attributi dopo la fase di pruning e derivazione




Figura 5: DFM / Fact Schema

- **Item Count (`item_count`)**

- **Descrizione:** Misura conteggio pre-impostata al valore unitario (1) per ogni record della Fact Table, poiché la granularità è fissata al singolo prodotto venduto (Sale Item).
- **Additività:** Totalmente Additiva (SUM). La misura può (e deve) essere sommata lungo tutte le dimensioni a qualsiasi livello gerarchico (es. numero totale di prodotti venduti in un determinato mese, o totale oggetti spediti da un venditore).

- **Prezzo (`price`)**

- **Descrizione:** Misura quantitativa monetaria che esprime il costo vivo del singolo prodotto (escluse le spese di trasporto).
- **Additività:** Totalmente Additiva (SUM). Misura cardine per calcolare le metriche di ricavo (Revenue). Può essere sommata trasversalmente lungo la dimensione temporale, demografica (clienti/venditori) o di prodotto (categoria) per estrarre insight sui flussi finanziari.

- **Costo di Spedizione (`freight_value`)**

- **Descrizione:** Misura quantitativa monetaria che quantifica le spese logistiche sostenute dal cliente per farsi recapitare l'oggetto.
- **Additività:** Totalmente Additiva (SUM). Estremamente utile per l'analisi dei costi di spedizione, in particolare se sommata per stato o regione (utilizzando la gerarchia geografica di `dim_customer` e `dim_seller`), permettendo di identificare le tratte logisticamente più care.

- **Punteggio Recensione (`review_score`)**

- **Descrizione:** Misura di gradimento associata all'ordine (da 1 a 5 stelle). È stata ereditata (propagandola) dal livello dell'ordine fino a quello del singolo item, per permettere analisi specifiche sulla soddisfazione cliente isolando i responsabili (es. capire se un voto basso è dovuto al prodotto scadente o alla logistica del venditore).
- **Additività:** Non Additiva (AVG). Contrariamente alle misure monetarie, la somma algebrica dei punteggi delle recensioni non produrrebbe alcun dato semanticamente rilevante. Questa metrica richiede aggregazioni tramite operatori non additivi, tipicamente la media statistica (Average), permettendo analisi dinamiche come la stima della valutazione media mensile o il rating medio di un venditore.

8 Star Schema

Il design logico adotta un'architettura Star Schema, ottimizzata per le query OLAP. A differenza dei sistemi operazionali, le tabelle dimensionali sono state completamente denormalizzate, consentendo l'accesso a tutte le coordinate analitiche attraverso una singola join con la Fact Table.




Figura 6: Star Schema logico-relazionale finale